

基于小波变换的 LLM 生成文本检测

从傅里叶到小波的技术改进

王梓硕 秦恺通 何林翰

June 1, 2025

FourierGPT 技术原理

核心思想：分析模型对文本的“不确定性曲线”

技术流程

- ① **NLL 序列生成**： $\text{NLL}(i) = -\log P(w_i | w_1, w_2, \dots, w_{i-1})$
- ② **傅里叶变换**： $X(k) = \sum_{n=0}^{N-1} \text{NLL}(n) \cdot e^{-i2\pi kn/N}$
- ③ **功率谱计算**： $\text{Power}(k) = |X(k)|^2$
- ④ **关键发现**：人类文本与 AI 文本在**低频分量**上存在显著差异
- ⑤ **分类判别**：基于低频分量差异进行二分类

解读：低频分量代表了那些频率低的长波形，对应了大尺度的基函数。也就是说，在文本相对长距离的信息的上人和机器生成文本差异较大。举个例子：长距离信息可能是主题，写作风格等，而短距离信息更可能是词语的衔接，使用方式等

FourierGPT 技术原理





Figure 1: The procedure (above) and example (below) of FourierGPT.

Figure: 示例图片：原论文中 FourierGPT 流程，以及低频差异

FourierGPT 的技术局限

核心问题：缺乏时间定位能力

- 全局平均化：只能得到整个文本的频率分布
- 时间盲区：无法知道频率差异出现在文本的哪个位置
- 信息丢失：某段落特征被其他段落“平均掉”

具体影响：

- 人类文本某段落的低频波动被平稳部分抵消导致整体低频功率与机器文本相似, 所以对长文本和复杂结构检测相对不稳定

小波变换：时频联合分析

技术对比

- 傅里叶变换： $NLL(t) \rightarrow \text{FFT} \rightarrow P(\omega)$
- 小波变换： $NLL(t) \rightarrow \text{Wavelet} \rightarrow P(a, b)$

小波变换公式：

$$W(a, b) = \frac{1}{\sqrt{a}} \sum_{t=0}^{n-1} NLL(t) \cdot \psi^* \left(\frac{t-b}{a} \right)$$

- a ：尺度参数（对应频率： $\text{freq} \propto 1/a$ ）
- b ：平移参数（对应时间位置）
- ψ ：小波基函数

小波变换的核心优势

时频局部化能力

- 时间定位：参数 b 提供精确的时间位置信息
- 频率分析：参数 a 提供多尺度的频率信息
- 自适应窗口：低频用宽窗口，高频用窄窗口

可以在一定程度上解决 **FourierGPT** 中无法确定低频差异位置问题：

- 分离不同时间段的低频能量贡献
- 避免全局平均化导致的信息丢失
- 同时捕捉局部细节和全局结构

特征提取策略对比

两种策略的技术验证：

策略 1：固定时间，计算频率功率和

- 意义：分析特定文本位置的多尺度特征
- 问题：可解释性差，随机性强
- 结果：效果不稳定，已舍弃

策略 2：固定频率，计算时间功率和

- 意义：同一尺度上，整个文本的上下文相关性
- 优势：可解释性强，效果稳定
- 结果：显著提升检测准确率

小波变换的关键技术发现

DWT vs CWT 对比：

- **DWT 优势：**计算高效，特征维度可控，对于近似尺度来说，可以将高频特征忽略，且近似特征是全局的，level=3 最佳
- **CWT 问题：**生成的 power 序列包含了 nll 序列中大部分 token 的信息，对于大 scale 来说，虽然统计的是全局信息，但是噪声过多过于冗余，导致效果不好，效果不如 DWT

DWT Level-3 分解效果最优

- 分解结果： $\text{coeffs} = [A_3, D_3, D_2, D_1]$
- 关键发现：近似系数 A_3 (freq=0) 区分度最大
- 最优 k 值：保证最优 k 值（前 k 个）处于区分度大的频率上（这里取 k=20）。解释：固定频率，计算时间功率和的时候，数据的排序是 A_3 分解的整个序列是最前面的，随后是 D_3 分解的序列...

小波变换的关键技术发现




Figure: 示例图片：离散小波变换提取特征后不同频段的 power 和差异

小波变换的关键技术发现




Figure: 示例图片：连续小波变换提取特征后不同频段的 power 和差异

PWH 分类

分类核心逻辑：

```
def classify_pair(x_human, x_model, k_freq, higher='model'):  
    power_human = sum(x_human[sid][ 'power' ][: k_freq])  
    power_model = sum(x_model[sid][ 'power' ][: k_freq])  
  
    if higher == 'model':  
        return power_model > power_human  
    else:  
        return power_human > power_model
```

k 值优化策略：

- 双向测试：同时测试'model higher' 和'human higher'
- 目标：选择准确率最高的 (k, higher) 组合

实验数据对比

Dataset	Gen. model	FFT	Est. model	Wavelet dwt	δ_k	Est. model	Wavelet cwt	δ_k	Est. model
Pubmed	GPT-4	0.9133	GPT2-xl	0.9600	10	Mistral	0.9267	193	Mistral
	GPT-3.5	0.9467	Mistral	0.9933	12	Mistral	0.9267	14	Mistral
	GPT-3	0.6867	Mistral	0.7400	92	Mistral	0.7000	2	Mistral
Writing	GPT-4	0.8467	GPT2-xl	0.9800	8	Mistral	0.9733	1	Mistral
	GPT-3.5	0.9200	Mistral	1.0000	8	Mistral	1.0000	1	Mistral
	GPT-3	0.7200	Mistral	0.8867	12	Mistral	0.9133	3	Mistral
Xsum	GPT-4	0.8733	GPT2-xl	0.8773	10	Mistral	0.9267	488	GPT2-xl
	GPT-3.5	0.9200	GPT2-xl	0.9933	1	Mistral	0.9933	2	Mistral
	GPT-3	0.6067	GPT2-xl	0.8400	212	Bigram	0.9067	189	Bigram

Figure: 在原始论文数据集上的表现

实验数据对比

Dataset	Gen. model	FFT	δ_k	Est. model	Wavelet dwf	δ_k	Est. model	Wavelet cwt	δ_k	Est. model
	Claude	0.8090	280	Ada	0.8990	8	Davinci	0.8850	23	Davinci
	GPT	0.8180	4	Davinci	0.8420	16	Davinci	0.7930	22	Davinci
Reuter	GPT-prompt1	0.7630	12	Davinci	0.8460	15	Davinci	0.8410	22	Davinci
	GPT-prompt2	0.7840	5	Davinci	0.8690	13	Davinci	0.9100	23	Davinci
	GPT-semantic	0.7630	13	Davinci	0.8920	9	Davinci	0.9170	26	Davinci
	GPT-writing	0.8110	5	Davinci	0.9430	10	Davinci	0.9370	25	Davinci

Figure: 新一批数据上 reuter 部分

实验数据对比

Dataset	Gen. model	FFT	δ_k	Est. model	Wavelet dwt	δ_k	Est. model	Wavelet cwt	δ_k	Est. model
	Claude	0.6190	25	Ada	0.8060	1	Davinci	0.8480	4	Davinci
	GPT	0.7770	25	Ada	0.7390	186	Davinci	0.6440	95	Davinci
Wp	GPT-prompt1	0.7640	28	Ada	0.7170	208	Davinci	0.7070	97	Davinci
	GPT-prompt2	0.6860	38	Ada	0.6820	187	Davinci	0.7720	21	Davinci
	GPT-semantic	0.7070	11	Ada	0.8390	41	Davinci	0.8610	2	Davinci
	GPT-writing	0.6450	344	Davinci	0.7800	87	Davinci	0.7140	2	Davinci

Figure: 新一批数据上 wp 部分

实验数据对比

Dataset	Gen. model	FFT	δ_k	Est. model	Wavelet dwf	δ_k	Est. model	Wavelet cwt	δ_k	Est. model
	Claude	0.6110	18	Ada	0.7660	1	Davinci	0.8120	1	Davinci
	GPT	0.7150	5	Davinci	0.8800	15	Davinci	0.8230	4	Davinci
Essay	GPT-prompt1	0.7560	4	Davinci	0.9280	13	Davinci	0.8880	10	Davinci
	GPT-prompt2	0.7250	4	Davinci	0.9540	16	Davinci	0.9110	4	Davinci
	GPT-semantic	0.7110	5	Davinci	0.9100	14	Davinci	0.8510	7	Davinci
	GPT-writing	0.7520	5	Davinci	0.9810	2	Davinci	0.9600	6	Davinci

Figure: 新一批数据上 essay 部分

未来工作方向

算法优化：

- 探索适合 NLP 任务的自定义小波基
- 目前小波变换可能并没有充分的利用到局部时间信息，可能在时频三维的图上进一步探索

应用拓展：

- 扩展到多语言文本检测
- [github:https://github.com/KaitongQin/FourierGPT](https://github.com/KaitongQin/FourierGPT)