

从Fourier到Wavelet

本学期创新实践的实验方向是通过wavelet处理nll的方法来提高人类机器文本分类的准确度。

背景

- 傅里叶通过计算每个token的负对数似然值，形成NLL序列（Negative Log-Likelihood），这个序列代表了机器对token预测的不确定性的loss

$$NLL(i) = -\log P(w_i | w_1, w_2, \dots, w_{i-1})$$

其中loss大代表突然高的不确定性，loss小代表平滑，更符合“机器生成”逻辑的字符。

随后有如z-score的标准化过程

- 随后使用傅里叶变换处理每个样本的loss序列，提取其频域信息：

$$X(k) = \sum_{n=0}^{N-1} NLLnorm(n) \cdot e^{(-i2\pi kn/N)}$$

其意义是用不同的sin和cos基函数去拟合NLLnorm的波形，不同频率的波的重要性系数可以之后计算成power

$$Power(k) = |X(k)|^2 = X(k) \cdot X^*(k)$$

$$Power(k) = [Re(X(k))]^2 + [Im(X(k))]^2$$

这里低频分量可以代表nll序列的长期趋势和缓慢变化（因为低频的波持续时间长，周期长），也就是从全局视角上看的变化，这种变化不易发现，因为距离长而难以观测，比如整篇文章的风格是否一致，主题是否变化。高频分量可以堪称NLL序列的快速波动和局部突变，这种变化相对好发现，比如上下两句话说的内容对不上。

- FourierGPT的论文中发现在低频分量上人类文本和机器生成文本存在显著差异。从而可以检测低频分量的差异来在一定程度上判断机器生成和人类文本的差异。

动机

小波变换作为最近比较热门的波分析方式，其优势是在保留一定频率信息的同时，赋予频率时间信息。但是由于海森堡不确定性原理，他的信息精度有所损失。我们想要尝试利用小波变换的时间信息（在这里是文本位置信息），让检测更加精准。

原理

小波变换和傅里叶变换一样，也分为连续和离散，连续也是由多个离散拟合，以下是他们的公式：

$$W(a, b) = (1/\sqrt{a}) \int_{-\infty}^{\infty} NLL(t) \cdot \psi * ((t - b)/a) dt$$

$$W(a, b) = (1/\sqrt{a}) \sum_{t=0}^{n-1} NLL(t) \cdot \psi * ((t - b)/a)$$

$$Power(a, b) = |W(a, b)|^2$$

$$Power(a, b) = R(a, b)^2 + I(a, b)^2$$

其中a是尺度参数（scale），对应了频率（freq $\propto$ 1/a）。b是平移参数，对应了时间。

类比fourierGPT，我们可以对其中频率和时间做处理得到以下两点思路：

- 固定频率，计算时间上power的和：意义为在同一个尺度上，整个文本的上下文相关性。

- 固定时间，计算频率上power的和：意义为在特定文本位置上，在不同尺度的上下文相关性。

实验

我们就上面两个思路做了实验：

固定时间，计算频率上power的和

可解释性差且随机性强，依赖于机器生成文本是否有特定的生成模式，在FourierGPT仓库上的实验结果较好，在新数据上相对较差。原因为仓库中的文本格式基本都是问答模式。而大语言模型在问答上有特定的回答格式，特别是answer中的格式，比如does, is发问，基本都是yes, no或者because回答，很有随机性。而在一些没有明显特征呢个的情况下，这种方法不幸，遂舍弃。

固定频率，计算时间上power的和

可解释性相对较强且效果更好。采用此方法，下面将详细讲解：

DWT：

使用pywt库进行小波分解，为了保持格式一样，我们最后生成的df中power是coef系数，freq代表了不同级别的小波分解，这样可以直接用傅里叶的代码继续后面的分类

生成的系数列列表是：


```
coeffs = [V0, W0, W1, ...]
```

其中A是分解后的近似系数，其他是细节系数，可以通过这个公式来还原信号

$$V_0 \oplus W_0 \oplus W_1 \oplus W_2 \dots \oplus W_{n-1} = V_n$$

其中近似系数代表了最粗糙，范围最广的信息，也就是对应了Fourier的低频信息。

我们对近似系数多个样本进行测试：




结果表示在level=3的离散小波分解下，用近似系数（freq=0）得到的power之和区分度较大。所以如果按照这个区间来进行select_k的话可能能对人类和机器文本做更好的区分。对于数据来说对应的k大概在20 左右

傅里叶变换无法分离不同时间段的低频能量贡献。例如，人类文本中某一段落的低频波动可能被其他段落的平稳部分抵消，导致的一定程度上整体低频功率与机器文本相似。

CWT：

由于cwt的卷及特性，生成的power序列包含了nll序列中大部分token的信息，对于大scale来说，虽然统计的是全局信息，但是噪声过多过于冗余，导致效果不好。而对于小scale来说，具有较好的细节分辨率，然而似乎由于机器生成文本和人类文本在细节上的差异不大，导致效果并不是那么优异。光看图好像看不出来什么区别，我们选定k=500 进行select_k测试（大概到freq=8的所有pwer向加）。



结果展示

Pubmed, Writing, Xsum

Dataset	Gen. model	FFT	Est. model	Wavelet dwf	δ_k	Est. model	Wavelet cwt	δ_k	Est. model
Pubmed	GPT-4	0.9133	GPT2-xl	0.9600	10	Mistral	0.9267	193	Mistral
	GPT-3.5	0.9467	Mistral	0.9933	12	Mistral	0.9267	14	Mistral
	GPT-3	0.6867	Mistral	0.7400	92	Mistral	0.7000	2	Mistral
Writing	GPT-4	0.8467	GPT2-xl	0.9800	8	Mistral	0.9733	1	Mistral
	GPT-3.5	0.9200	Mistral	1.0000	8	Mistral	1.0000	1	Mistral
	GPT-3	0.7200	Mistral	0.8867	12	Mistral	0.9133	3	Mistral
Xsum	GPT-4	0.8733	GPT2-xl	0.8773	10	Mistral	0.9267	488	GPT2-xl
	GPT-3.5	0.9200	GPT2-xl	0.9933	1	Mistral	0.9933	2	Mistral
	GPT-3	0.6067	GPT2-xl	0.8400	212	Bigram	0.9067	189	Bigram

Ghostbuster: essay

Dataset	Gen. model	FFT	δ_k	Est. model	Wavelet dwt	δ_k	Est. model	Wavelet cwt	δ_k	Est. model
	Claude	0.8470	149	Davinci	0.7660	1	Davinci	0.8120	1	Davinci
	GPT	0.8520	172	Davinci	0.8800	15	Davinci	0.8230	4	Davinci
Essay	GPT-prompt1	0.8190	163	Davinci	0.9280	13	Davinci	0.8880	10	Davinci
	GPT-prompt2	0.8400	154	Davinci	0.9540	16	Davinci	0.9110	4	Davinci
	GPT-semantic	0.8990	170	Davinci	0.9100	14	Davinci	0.8510	7	Davinci
	GPT-writing	0.7830	161	Davinci	0.9810	2	Davinci	0.9600	6	Davinci

Ghostbuster: wp

Dataset	Gen. model	FFT	δ_k	Est. model	Wavelet dwt	δ_k	Est. model	Wavelet cwt	δ_k	Est. model
	Claude	0.7540	81	Davinci	0.8060	1	Davinci	0.8480	4	Davinci
	GPT	0.9190	88	Davinci	0.7390	186	Davinci	0.6440	95	Davinci
Wp	GPT-prompt1	0.8800	99	Davinci	0.7170	208	Davinci	0.7070	97	Davinci
	GPT-prompt2	0.8760	63	Davinci	0.6820	187	Davinci	0.7720	21	Davinci
	GPT-semantic	0.9250	72	Davinci	0.8390	41	Davinci	0.8610	2	Davinci
	GPT-writing	0.6210	110	Davinci	0.7800	87	Davinci	0.7140	2	Davinci